

知能情報実験 III（データマイニング班）
競馬複勝予測

グループの学籍番号 245725D, 245304F, 245731J, 235751J

提出日：2026 年 6 月 9 日

目次

1	本実験向け補足	2
1.1	テーマ：競馬予測とは	2
1.2	競馬複勝予測とは	2
1.3	実験計画（中間報告用）	2
1.4	実験目的	3
1.5	実験手順（中間報告時点）	3
1.6	データセット	4
1.7	モデル	4
1.8	パラメータ調整	4

1 本実験向け補足

1.1 テーマ：競馬複勝予測とは

本グループでは、競馬における馬の複勝率予測を対象問題として設定した。複勝とは、出走した馬が3着以内に入るかどうかを予測する馬券の種類であり、単勝や馬連と比較して的中しやすい特徴を持つ。本テーマでは、過去の競馬データを用いて、各馬が複勝するか否かを機械学習によって分類することを目的とする。競馬では、馬の年齢や体重、レース距離、天候、馬場状態など多くの要因がレース結果に影響すると考えられている。しかし、人間がこれらの膨大な情報を総合的に判断して予測を行うことは容易ではない。そこで、機械学習を活用することで、多数の説明変数から複勝に関係する特徴を学習し、客観的な予測を行うことが可能となる。

本テーマに取り組む意義は、実際の競馬予想への応用だけでなく、多数の特徴量を持つ実データに対して分類モデルを適用し、その性能や特徴量の重要度を分析できる点にある。これにより、機械学習を用いた予測手法の有効性を検証するとともに、データ分析の実践的な知識を深めることができる。

1.2 実験計画（中間報告用）

本グループでは4名で役割分担を行い、2名がデータの加工を担当し、残りの2名が機械学習モデルの実装および評価を担当する。

まず、1週目はデータ担当者が競馬の過去レースデータを収集し、欠損値や異常値の確認、不要な列の削除などの前処理を行う。また、複勝した馬を1、複勝しなかった馬を0とする教師データを作成する。一方、機械学習担当者は使用するライブラリやモデルの調査を行い、学習環境の構築およびベースラインモデルの作成を進める。

2週目は、データ担当者がカテゴリ変数のエンコーディングや特徴量の整理を行い、学習に利用できるデータセットを完成させる。機械学習担当者は完成したデータセットを用いて学習を実施し、正解率や適合率、再現率などの評価指標を算出する。また、特徴量重要度の分析を行い、予測に大きく影響する要素を調査する。

その後は、得られた結果を基にPDCAサイクルを回す。まず学習結果を分析し、予測精度が低い場合には原因を検討する。例えば、特徴量不足やデータの偏り、モデル選択の問題などを考察する。その分析結果を踏まえて、新たな特徴量の追加や不要特徴量の削除、ハイパーパラメータの調整、別モデルの適用などの改善策を実施する。改善後のモデルを再度評価し、性能向上の有無を確認する。

最終的には、複数のモデルの性能比較を行い、どのような特徴量が複勝予測に有効であったかを考察する。また、実験結果をまとめ、機械学習による競馬予測の有効性と課題について報告する予定である。

1.3 実験目的

本実験の目的は、競馬の過去データを用いて機械学習モデルを構築し、出走馬が複勝（3 着以内に入着）するかどうかを予測できるかを検証することである。競馬のレース結果には、馬齢、馬体重、距離、天候、馬場状態など多くの要因が関係していると考えられるため、これらの特徴量から複勝の可否を予測する分類モデルを作成する。また、複数の特徴量を用いた機械学習によってどの程度の予測性能が得られるのかを評価するとともに、どの特徴量が複勝予測に大きく影響しているのかを分析することも目的とする。さらに、異なる機械学習手法や前処理方法を比較し、それらが予測精度に与える影響を検証する。これらの実験を通して、競馬における複勝予測の実現可能性を確認するとともに、実データを対象とした機械学習モデル構築の有効性について考察する。

1.4 実験手順（中間報告時点）

本実験では、Kaggle で公開されている JRA 競馬データセットを用いて、出走馬が複勝（3 着以内入着）するかどうかを予測する二値分類問題に取り組む予定である。

まず、データセットから競走馬の情報を抽出し、目的変数を作成する。目的変数は着順を基に作成し、3 着以内を 1、4 着以下を 0 とする予定である。また、馬齢、馬体重、馬体重増減、距離、天候、馬場状態などの特徴量を説明変数として利用する。欠損値の処理やカテゴリ変数のエンコーディングなどの前処理を行い、機械学習で利用可能な形式へ変換する。

次に、データを訓練データとテストデータに分割し、訓練データを用いて機械学習モデルの学習を行う予定である。モデルとしてはロジスティック回帰や XGBoostなどを候補とし、性能を比較する。

評価には正解率（Accuracy）、F1 スコアを用いる予定である。さらに、特徴量やハイパーパラメータを変更しながら性能を比較し、複勝予測に適したモデルを検討する。

最終的には、各モデルの評価結果を比較し、競馬の複勝予測に対する機械学習の有効性について考察する予定である。

1.5 データセット

https://www.kaggle.com/datasets/takamotoki/jra-horse-racing-dataset?select=19860105-20210731_race_result.csv

このデータセットは、JRA（日本中央競馬会）の競馬データを収録したものであり、1986 年から 2021 年までのレース結果、オッズ、ラップタイム、コーナー通過順位などの情報を含む。データは競馬情報サイト「netkeiba.com」から収集・整形されたものである。本研究では、その中の race_result.csv を主に利用する。このファイルには各レースに出走した馬ごとの情報が記録されており、馬体重、馬体重増減、馬齢、競馬場、距離、天候、馬場状態、騎手など、多数の説明変数が含まれている。

1.6 モデル

- ロジスティック回帰
- XGBoost
- RandomForest

本実験では、ロジスティック回帰、Random Forest、XGBoost の 3 種類のモデルを採用した。ロジスティック回帰は線形モデルであり、分類問題におけるベースラインとして広く用いられていることから、他のモデルとの比較基準として選択した。Random Forest は複数の決定木を組み合わせるアンサンブル学習手法であり、特徴量間の非線形な関係を学習できることから採用した。

また、競馬予測をはじめとする表形式データを対象とした機械学習では、勾配ブースティングを用いた XGBoost や LightGBM が高い予測性能を示すモデルとして広く利用されている。本実験では、その中でも XGBoost を採用した。XGBoost は分類問題において高い予測性能を示す実績が多く、参考資料や実装例が豊富である。また、特徴量重要度を算出できるため、予測性能の評価だけでなく、複勝予測に影響する特徴量の分析にも適している。さらに、初期設定でも比較的安定した学習が可能であり、本実験で扱うデータ規模では LightGBM の高速性よりも、安定性や実績を重視した。

以上のように、線形モデル、バギング、ブースティングという異なる性質を持つ 3 種類のモデルを比較することで、それぞれの特徴や性能の違いを明らかにし、競馬複勝予測に適した手法を検討することを目的とした。

1.7 パラメータ調整

なし